INSTITUTO DE INFORMÁTICA
Universidade Federal de Goiás

Utilizando Rede Neural Convolucional para Diagnóstico de Covid-19

Milton Alexandre Souza Demarchi
Yuri dos Reis de Oliveira
Professor: Ricardo Augusto Pereira Franco

INSTITUTO DE INFORMÁTICA
UFG

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Sumário

- Introdução
  - Formulação
  - Dataset
  - Objetivos
- Metodologia
- Resultados e Discussão
- Conclusão

Introdução

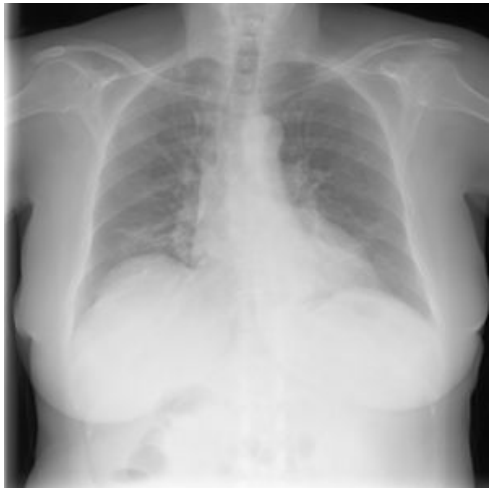
Formulação do Problema

- Pandemia de COVID-19;
- Importância do diagnóstico rápido e preciso;
- Raios-X torácicos como uma ferramenta diagnóstica crucial



[20, 50]

Formulação do Problema



COVID-19



Pneumonia Viral



Saudável

[20, 50]

Dataset

TAWSIFUR RAHMAN AND 2 COLLABORATORS · UPDATED 2 YEARS AGO

921 | New Notebook | Download (816 MB)

COVID-19 Radiography Database

COVID-19 Chest X-ray images and Lung masks Database



Data Card | Code (324) | Discussion (24)

About Dataset

----------UPDATED----------UPDATED----------UPDATED----------

---------- (3616 COVID-19 Chest X-ray images and lung masks) ----------

COVID-19 RADIOGRAPHY DATABASE (Winner of the COVID-19 Dataset Award by Kaggle Community)

A team of researchers from Qatar University, Doha, Qatar, and the University of Dhaka, Bangladesh along with their collaborators from Pakistan and Malaysia in collaboration with medical doctors have created a database of chest X-ray images for COVID-19 positive cases along with Normal and Viral Pneumonia images. This COVID-19, normal, and other lung infection dataset is released in stages. In the first release, we have released 219 COVID-19, 1341 normal, and 1345 viral pneumonia chest X-ray (CXR) images. In the first update, we have

Usability
10.00

License
Data files © Original Authors

Expected update frequency
Monthly

Tags
Earth and Nature | Health | Universities and Colleges

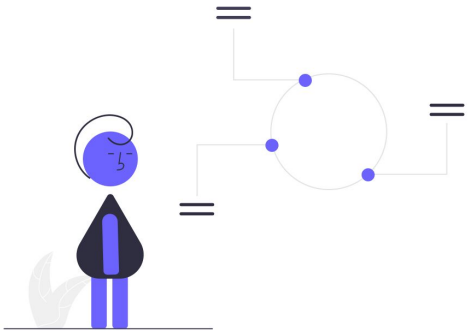
[20, 50]

Dataset

- Classes:
  - COVID-19;
  - Pneumonia Viral;
  - Pacientes saudáveis (Normal).

- Quantidade de imagens disponíveis

  - 3616 de casos positivos de COVID-19;
  - 1345 de casos de Pneumonia Viral;
  - 10192 de casos de pacientes sem a doença.



[20, 50]

Objetivos

- Objetivo Geral
  - Desenvolver e aprimorar um modelo de inteligência artificial baseado em redes neurais convolucionais, utilizando o COVID-19 Radiography Database, para a detecção precisa de casos de COVID-19 a partir de imagens radiográficas do tórax.

Objetivos

- Objetivos específicos
  - Implementar e Treinar a Rede Neural Convolucional para classifcar imagens de raio-x dentre as classes Covid-19, pneumonia viral e saudável (normal);
  - Aprofundar conhecimentos sobre Redes Neurais Convolucionais;
  - Analisar e Comparar Implementações Existentes para o mesmo objetivo;
  - Alcançar uma Taxa Significativa de Acurácia;

Metodologia

Baseline



- Identificação da baixa acurácia no código original, **abaixo de 25%**;
- Reconhecimento de erros no código e ajustes para que seja possível compará-lo com futuros modelos.
    - Classificação binária -> multiclasse
    - Gerando o que denominamos modelo “**Minimamente Modificado**”.
        - Acurácia em torno de 94,46%.

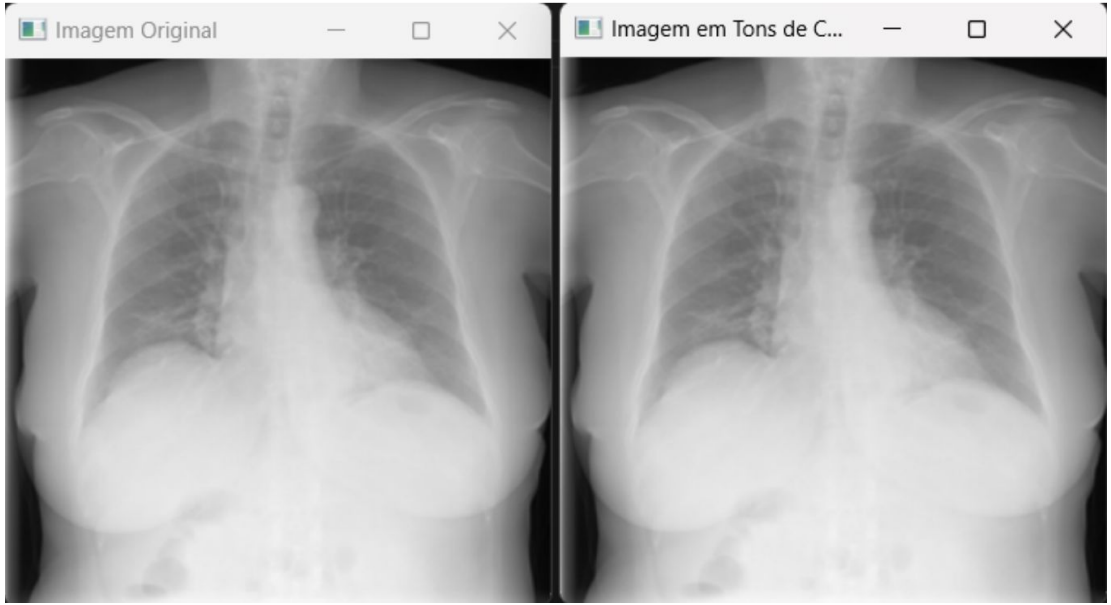
Experimentação e Ajustes no Modelo

- Testes exploratórios adicionando camadas, alterando quantidade de filtros e parâmetros no geral;
- Explorando quantidade de épocas: 5 -> 10
- Modelo Por Exploratório foi alterado até que tivéssemos o seguinte:

```
Conv2D(8,3,input_shape = (100,100,3),activation ='relu'),
MaxPooling2D(),
Conv2D(16,3,activation ='relu'),
MaxPooling2D(),
Conv2D(32,3,activation ='relu'),
MaxPooling2D(),
Flatten(),
Dense(1000,activation ='relu'),
Dense(3,activation ='softmax'),
```

Otimização com Escala de Cinza

- Imagens de raio-X não precisam ser representadas em RGB;
- Testes para verificar a viabilidade;
- Ajuste do modelo para operar com um único canal.



Otimização com Escala de Cinza

Parâmetros da primeira convolução serão diminuídos em uma escala de 3.

- Mesmo resultado;
- Melhor performance.

E desta forma forma obtivemos o modelo que denominamos “**Modelo por Exploratório**”.

Acurácia em torno de **95,32%**.

```
Conv2D(8, 3, input_shape = (100, 100, 1), activation = 'relu'),
MaxPooling2D(),
Conv2D(16, 3, activation = 'relu'),
MaxPooling2D(),
Conv2D(32, 3, activation = 'relu'),
MaxPooling2D(),
Flatten(),
Dense(1000, activation = 'relu'),
Dense(3, activation = 'softmax'),
```

Incorporação da DenseNet-121

- Aqui já havíamos alterado o modelo original de Jihad Hosan de forma a gerar 2 novos modelos com acurácias melhores:

    1) Minimamente alterado: incrementado multiclasse - 94.46% de acurácia.
    2) Camadas alteradas de forma geral - 94,52% de acurácia.

- Por fim, um novo modelo foi testado, utilizando arquitetura DenseNet-121, onde temos:

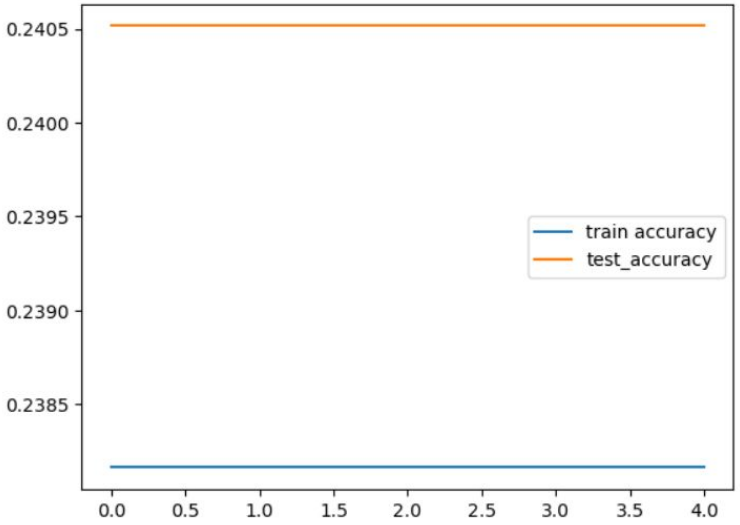
    - 1 Convolução 7x7
    - 58 Convoluções 3x3
    - 61 Convoluções 1x1
    - 4 AvgPool (Pooling Médio)
    - 1 Camada Totalmente Conectada

98,58% de acurácia!

Resultados e Discussão

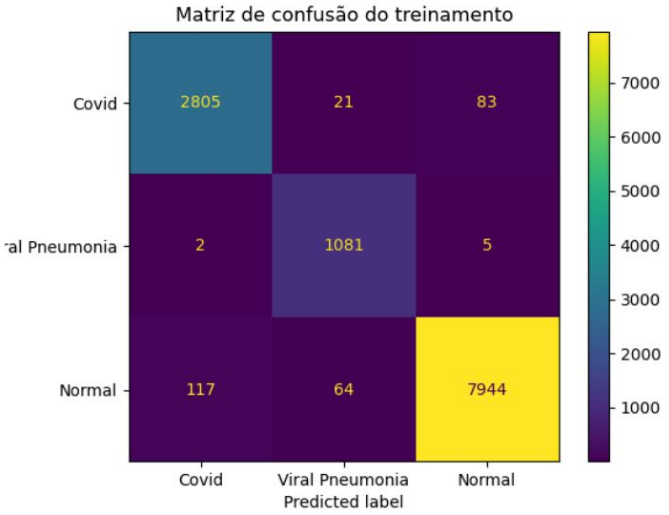
Baseline

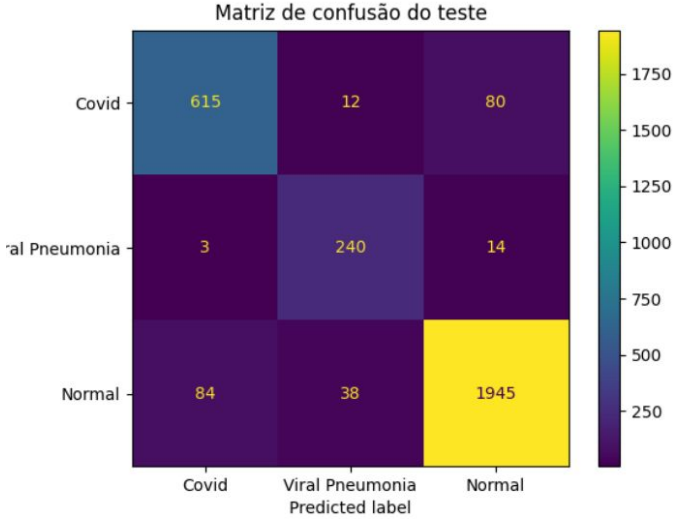
- Modelo Original do JAHID HASAN
  - Acurácia: 24%
  - Desafios: erros de código, classificação binária, acurácia baixíssima por conta dos erros, etc.



Modelo Minimamente Modificado

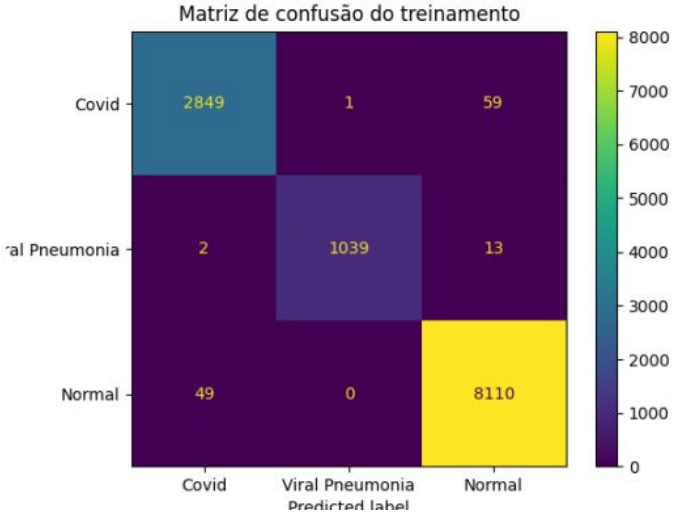
- Acurácia: 94,46%;
- Principal melhoria: Classificação multiclasse;
- Desempenho: Aumento significativo em precisão, recall e F1-score.

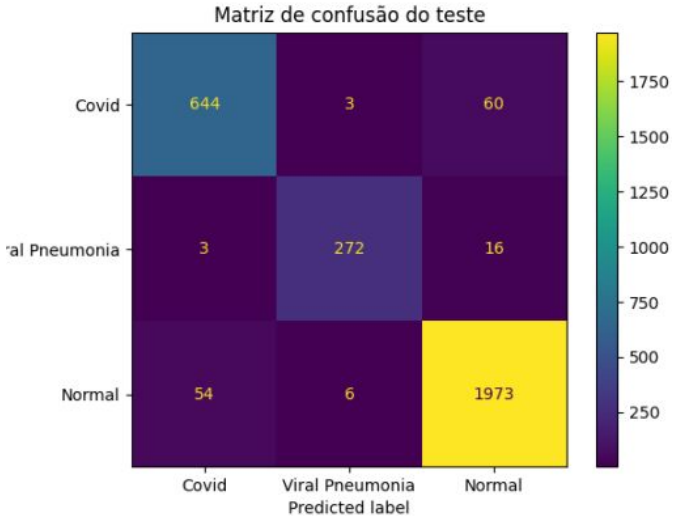




Modelo Por Exploratório

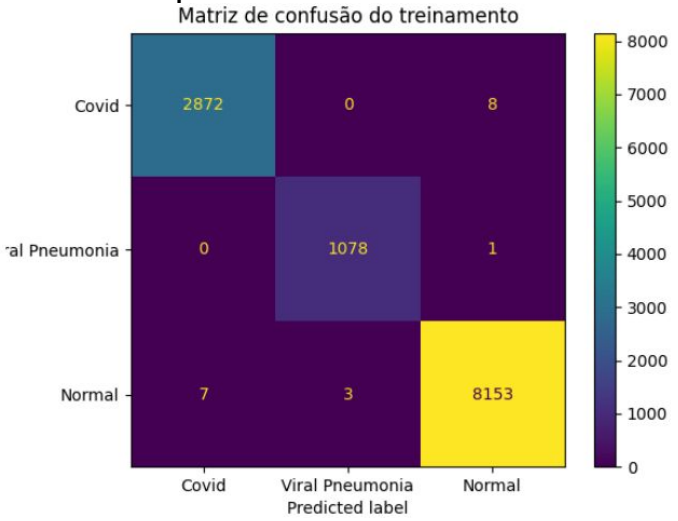
- Acurácia: 95,32%;
- Principais melhorias: desempenho e melhora na acurácia;
- Redução de ⅓ do tempo de treinamento

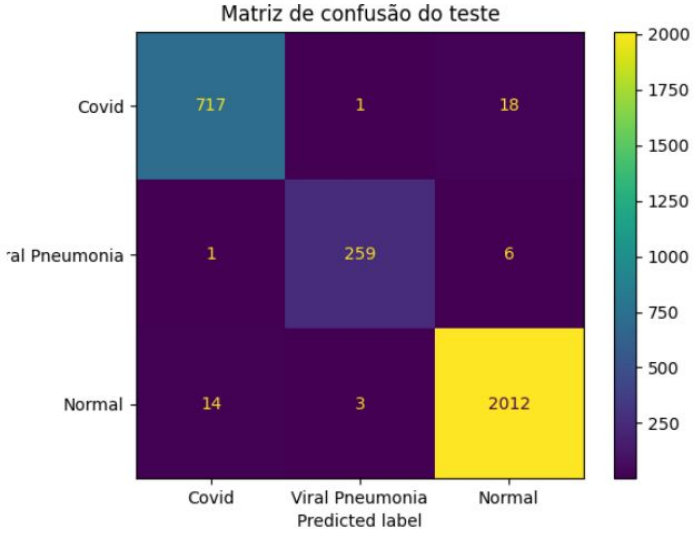




Modelo Utilizando Arquitetura DenseNet-121

- Acurácia: **98,58%**
- Desempenho: Excepcional em todas as classes.
- Contras: maior tempo (17x) para execução quando comparado ao modelo por exploratório.



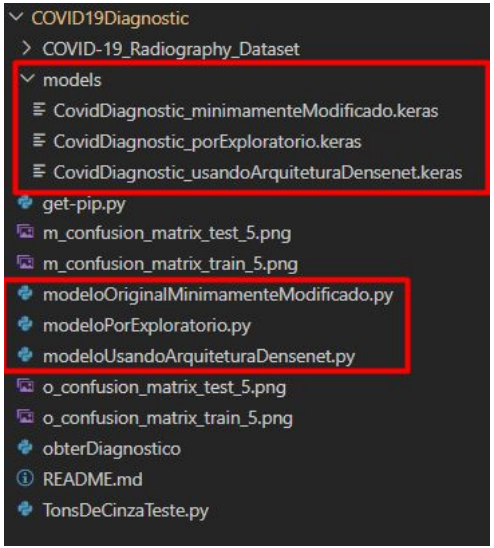


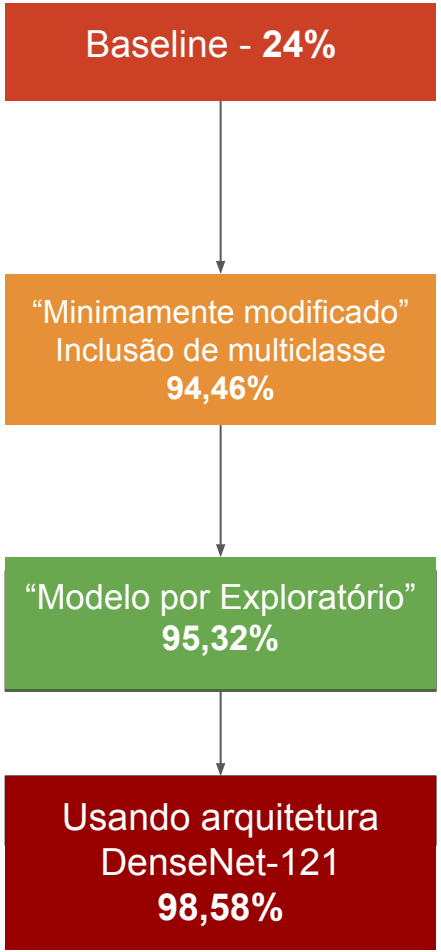
Métricas gerais

Modelo	Acurácia	Precisão	F1-Score
Original	24%	–	–
Minimamente Alterado	94.46%	94.37%	94.36%
Exploratório	95.32%	95.26%	95.27%
DenseNet-121	98.58%	98.58%	98.58%

Tabela 3.1: Métricas de Desempenho dos Modelos (média ponderada)

Melhoria de acurácia nos modelos criados





Conclusão

Conclusão

- A otimização do modelo original resultou em melhorias significativas na acurácia;
- Com este trabalho foi possível não apenas melhorar um código já existente como criar diferentes modelos a partir dele e analisá-los de forma independente;
- Foi visto que os modelos criados podem colaborar de forma significativa para diagnósticos com maior precisão e melhor desempenho.

Como perspectiva futura, sugerimos a utilização do recém-lançado conjunto de dados COVID-QU-Ex, proveniente dos mesmos autores do dataset original deste estudo. Este novo conjunto de dados oferece uma quantidade maior de dados, proporcionando assim um maior poder de generalização para futuras pesquisas

Repositório para código fonte e modelos: https://github.com/YuriReiss/COVID19Diagnostic

Referência Bibliográfica

[1] António Vaz Carneiro e Susana Neto. "ISBE Newsletter nº 61: O raio X de tórax pode constituir um exame muito útil no diagnóstico clínico da Covid-19-Não existem publicações de boa qualidade com dados sobre apoio psicológico aos profissionais de saúde". Em: *ISBE Newsletter* 61 (2020).

[2] Muhammad EH Chowdhury et al. "Can AI help in screening viral and COVID-19 pneumonia?" Em: *Ieee Access* 8 (2020), pp. 132665–132676.

[3] Tawsifur Rahman et al. "Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images". Em: *Computers in biology and medicine* 132 (2021), p. 104319.

Obrigado!

Vamos aos testes!

INSTITUTO DE INFORMÁTICA UFG

UFG UNIVERSIDADE FEDERAL DE GOIÁS